總覽與需求

BeeGFS on NetApp with E-Series Storage

NetApp
March 21, 2024

This PDF was generated from https://docs.netapp.com/zh-tw/beegfs/beegfs-solution-overview.html on March 21, 2024. Always check docs.netapp.com for the latest.

目錄

總覽與需求 1
解決方案總覽 1
設計世代 2
架構總覽 3
技術需求 5

總覽與需求

解決方案總覽

BeeGFS on NetApp解決方案結合BeeGFS平行檔案系統與NetApp EF600儲存系統、打造可靠、可擴充且具成本效益的基礎架構、可跟上嚴苛工作負載的腳步。

此設計充分利用最新企業伺服器與儲存硬體及網路速度所提供的效能密度、 需要具備雙AMD EPYC 7003「Milan」處理器的檔案節點、並支援PCIe 4.0、並使用200GB（HDRs）InfiniBand直接連線至區塊節點、以使用NVMe/IB傳輸協定提供端點對端NVMe和NVMeoF。

NVA方案

NetApp上的BeeGFS解決方案是NetApp驗證架構（NVA）方案的一部分、可為客戶提供特定工作負載和使用案例的參考組態和規模調整指導。NVA解決方案經過徹底測試與設計、可將部署風險降至最低、並加速上市時間。

使用案例

下列使用案例適用於NetApp上的BeeGFS解決方案：

- 人工智慧（AI）包括機器學習（ML）、深度學習（DL）、大規模自然語言處理（NLP）、以及自然語言理解（N5U）。如需詳細資訊、請參閱 "BeeGFS for AI：事實與虛構"。
- 高效能運算（HPC）、包括透過MPI（訊息傳遞介面）和其他分散式運算技術加速的應用程式。如需詳細資訊、請參閱 "為什麼BeeGFS超越HPC"。
- 應用程式工作負載的特徵為：
  - 讀取或寫入大於1GB的檔案
  - 由多個用戶端（10s、100s和1000s）讀取或寫入同一個檔案
- 多TB或數PB資料集。
- 需要單一儲存命名空間的環境、可針對大型與小型檔案的組合進行最佳化。

效益

在NetApp上使用BeeGFS的主要優點包括：

- 通過驗證的硬體設計可提供完整的硬體與軟體元件整合、確保可預測的效能與可靠性。
- 使用Ansible進行部署與管理、以達到簡化與大規模一致的目標。
- 使用E系列效能分析器和BeeGFS外掛程式提供監控和觀察能力。如需詳細資訊、請參閱 "介紹監控NetApp E系列解決方案的架構"。
- 高可用度採用共享磁碟架構、提供資料持久性與可用度。
- 使用Container和Kubernetes支援現代化的工作負載管理與協調。如需詳細資訊、請參閱 "Kubernetes與BeeGFS會面：這是一段符合未來需求的投資故事"。

HA架構

NetApp的BeeGFS透過NetApp硬體打造完全整合的解決方案、實現共享磁碟高可用度（HA）架構、擴充BeeGFS企業版的功能。

> 雖然BeeGFS社群版本可以免費使用、但企業版需要向NetApp等合作夥伴購買專業支援訂閱合約。企業版允許使用多項額外功能、包括恢復能力、配額強制和儲存資源池。

下圖比較了共享無共享和共享磁碟HA架構。

[]

如需詳細資訊、請參閱 "發表NetApp支援的BeeGFS高可用度"。

Ansible

NetApp上的BeeGFS是使用Ansible Automation（位於GitHub和Ansible Galaxis）（BeeGFS收藏可從取得）來交付及部署 "Ansible Galaxy" 和 "NetApp的E系列GitHub"）。雖然Ansible主要是針對用來組裝BeeGFS建置區塊的硬體進行測試、但您可以設定它在任何使用支援Linux套裝作業系統的x86型伺服器上執行。

如需詳細資訊、請參閱 "部署BeeGFS搭配E系列儲存設備"。

設計世代

BeeGFS on NetApp解決方案目前正處於第二代設計階段。

第一代和第二代均採用基礎架構、整合BeeGFS檔案系統和NVMe EF600儲存系統。然而、第二代產品是以第一代產品為基礎、提供下列額外效益：

- 效能與容量加倍、同時只增加2U機架空間
- 高可用度（HA）是以共享磁碟、雙層硬體設計為基礎
- NVIDIA DGX A100 SupermPOD與NVIDIA BasePOD架構的外部資格

第二代設計

NetApp的第二代BeeGFS已經過最佳化、可滿足嚴苛工作負載的效能需求、包括高效能運算（HPC）和HPC型機器學習（ML）、深度學習（DL）和類似的人工智慧（AI）技術。透過採用共享磁碟高可用度（HA）架構、NetApp上的BeeGFS解決方案也能滿足企業和其他組織的資料耐用度和可用度需求、這些企業和組織在尋找能夠隨工作負載和使用案例而擴充的儲存設備時、無法承受停機或資料遺失的風險。此解決方案不僅已通過NetApp驗證、也已通過外部認證、成為NVIDIA DGX超級POD和DGX基礎POD的儲存選項。

第一代設計

NetApp的第一代BeeGFS是專為使用NetApp EF600 NVMe儲存系統、BeeGFS平行檔案系統、NVIDIA DGX™A100系統及NVIDIA®Mellanox®Quantum™QM8700 200Gbps IB交換器的機器學習（ML）和人工智慧（AI）工作負載所設計。此設計也針對儲存設備和運算叢集互連架構提供200Gbps InfiniBand（IB）、為高效能工作負載提供完全以IB為基礎的架構。

如需第一代產品的詳細資訊、請參閱 "NetApp EF系列AI搭配NVIDIA DGX A100系統和BeeGFS"。

架構總覽

NetApp上的BeeGFS解決方案包含架構設計考量、可用來判斷支援已驗證工作負載所需的特定設備、纜線和組態。

建置區塊架構

BeeGFS檔案系統可根據儲存需求以不同方式進行部署和擴充。例如、主要包含大量小型檔案的使用案例、將可從額外的中繼資料效能和容量中獲益、而較少大型檔案的使用案例、則可能會讓實際檔案內容的儲存容量和效能更高。這些多重考量因素會影響平行檔案系統部署的不同層面、進而增加設計和部署檔案系統的複雜度。

為了因應這些挑戰、NetApp設計了標準建置區塊架構、用於橫向擴充這些層面。通常、BeeGFS建置區塊會部署在三種組態設定檔中的其中一種：

- 單一基礎建置區塊、包括BeeGFS管理、中繼資料和儲存服務
- BeeGFS中繼資料加上儲存建置區塊
- BeeGFS僅儲存建置區塊

這三個選項之間唯一的硬體變更是使用較小的磁碟機來處理BeeGFS中繼資料。否則、所有組態變更都會透過軟體套用。使用Ansible做為部署引擎、為特定建置區塊設定所需的設定檔、可讓組態工作變得簡單明瞭。

如需詳細資料、請參閱 [已驗證硬體設計]。

檔案系統服務

BeeGFS檔案系統包含下列主要服務：

- *管理服務。*註冊並監控所有其他服務。
- *儲存服務。*儲存稱為資料區塊檔案的分散式使用者檔案內容。
- *中繼資料服務。*會追蹤檔案系統配置、目錄、檔案屬性等。
- *用戶端服務。*掛載檔案系統以存取儲存的資料。

下圖顯示了與NetApp E系列系統搭配使用的BeeGFS解決方案元件和關係。

[]

作為平行檔案系統、BeeGFS會將其檔案等量磁碟區化到多個伺服器節點上、以最大化讀寫效能和擴充性。伺服器節點可共同運作、提供單一檔案系統、讓其他伺服器節點（通常稱為_Clients_）同時掛載及存取。這些用戶端可以像NTFS、XFS或ext4等本機檔案系統一樣、查看及使用分散式檔案系統。

這四項主要服務可在多種支援的Linux套裝作業系統上執行、並可透過任何支援TCP/IP或RDMA的網路進行通訊、包括InfiniBand（IB）、OMNI-Path（opa）和RDMA over Converged Ethernet（roce）。BeeGFS伺服器服務（管理、儲存及中繼資料）是使用者空間精靈、而用戶端則是原生核心模組（無修補程式）。所有元件均可在不重新開機的情況下安裝或更新、而且您可以在同一個節點上執行任何服務組合。

已驗證節點

NetApp上的BeeGFS解決方案包含下列通過驗證的節點：NetApp EF600儲存系統（區塊節點）和Lenovo

ThinkSystem SR665 Server（檔案節點）。

區塊節點：**EF600**儲存系統

NetApp EF600 All Flash Array提供一致、近乎即時的資料存取、同時支援任意數量的工作負載。EF600儲存系統為AI和HPC應用程式提供快速且持續的資料饋送功能、可在單一機箱中提供高達200萬個快取讀取IOPS、100微秒以下的回應時間、以及42GBps循序讀取頻寬。

檔案節點：**Lenovo ThinkSystem SR665**伺服器

SR665是雙插槽2U伺服器、搭載PCIe 4.0。當設定為符合此解決方案的需求時、它可提供充分的效能、在組態中執行BeeGFS檔案服務、並與直接附加E系列節點所提供的處理量和IOPs的可用度保持良好平衡。

如需Lenovo SR665的詳細資訊、請參閱 "聯想的網站"。

已驗證硬體設計

解決方案的建置區塊（如下圖所示）使用雙插槽PCIe 4.0伺服器作為BeeGFS檔案層、使用兩個EF600儲存系統作為區塊層。

[]

> 由於每個建置區塊都包含兩個BeeGFS檔案節點、因此在容錯移轉叢集中建立仲裁所需的建置區塊至少要有兩個。雖然您可以設定雙節點叢集、但此組態具有限制、可能會導致容錯移轉失敗。如果您需要雙節點叢集、可以將第三個裝置整合為斷路器（不過、此站台並未涵蓋該設計）。

每個建置區塊都能透過雙層硬體設計、將檔案層和區塊層的故障網域區隔開來、提供高可用度。每個層級都能獨立容錯移轉、提供更高的恢復能力、並降低串聯故障的風險。搭配NVMeoF使用HDRInfiniBand可在檔案和區塊節點之間提供高處理量和最低延遲、並提供完整備援和足夠的連結超額訂閱、以避免分散式設計成為瓶頸、即使系統部分降級。

NetApp上的BeeGFS解決方案可在部署中的所有建置區塊上執行。部署的第一個建置區塊必須執行BeeGFS管理、中繼資料和儲存服務（稱為基礎建置區塊）。所有後續的建置區塊都是透過軟體設定、以執行BeeGFS中繼資料和儲存服務、或僅執行儲存服務。每個建置區塊的不同組態設定檔可用度、可利用相同的基礎硬體平台和建置區塊設計來擴充檔案系統中繼資料或儲存容量和效能。

獨立式Linux HA叢集最多可合併五個建置區塊、確保每個叢集資源管理程式（起搏器）擁有合理數量的資源、並減少維持叢集成員同步所需的訊息傳輸負荷（電暈器同步）。建議每個叢集至少有兩個建置區塊、以允許足夠的成員建立仲裁。其中一個或多個獨立式BeeGFS HA叢集會結合在一起、以建立一個BeeGFS檔案系統（如下圖所示）、可供用戶端作為單一儲存命名空間存取。

[]

雖然每個機架的建置區塊數量最終取決於特定站台的電力和冷卻需求、 此解決方案的設計可在單一42U機架中部署最多五個建置區塊、同時仍可容納兩個用於儲存/資料網路的1U InfiniBand交換器。每個建置區塊都需要八個IB連接埠（每個交換器四個用於備援）、因此五個建置區塊會在40埠的HDRInfiniBand交換器（例如NVIDIA QM8700）上留下一半的連接埠、以供實作fat樹狀結構或類似的非區塊拓撲。這項組態可確保儲存設備或運算/GPU機架的數量能夠擴充、而不會產生網路瓶頸。或者、您也可以根據儲存架構廠商的建議、使用超額訂閱的儲存架構。

下圖顯示80節點的fat樹狀結構拓撲。

[]

藉由使用Ansible做為部署引擎、在NetApp上部署BeeGFS、系統管理員可以使用現代化的基礎架構做為程式碼實務、來維護整個環境。如此可大幅簡化原本複雜的系統、讓系統管理員能夠在同一個位置定義及調整組態、無論環境的規模有多大、都能確保系統一致地套用組態。BeeGFS系列可從取得 "Ansible Galaxy" 和 "NetApp的E系列GitHub"。

技術需求

若要在NetApp上實作BeeGFS解決方案、請確定您的環境符合技術需求。

硬體需求

下表列出在NetApp解決方案上實作單一第二代建置區塊設計所需的硬體元件。

> 解決方案的任何特定實作所使用的硬體元件、可能會因客戶需求而異。

數	硬體元件	需求
2.	BeeGFS檔案節點。	每個檔案節點都應符合或超過下列組態、以達到預期的效能。 處理器： • 2個AMD EPYC 7343 16C 3.2 GHz。 • 設定為兩個NUMA區域。 記憶體： • 256GB。 • 16x 16GB Truc4 3200MHz（2RX8 1.2V）RDIMM A（較少的DIMM容量更小）。 • 以最大化記憶體頻寬。 • PCIe擴充：四個PCE Gen4 x16插槽：* • 每個NUMA區域有兩個插槽。 • 每個插槽都應為Mellanox MCX653106A-HDAT介面卡提供足夠的電力/冷卻能力。 雜項： • 在RAID 1中為作業系統設定兩個1TB 7.2K SATA磁碟機（或類似磁碟機）。 • 10GbE OCP 3.0介面卡（或類似的）、適用於頻內作業系統管理。 • 1GbE BMC搭配Redfish API、可進行頻外伺服器管理。 • 雙熱交換電源供應器與效能風扇。 • 如果需要連接儲存InfiniBand交換器、則必須支援Mellanox光纖InfiniBand纜線。 聯想**SR665-** • 自訂的NetApp機型包括所需的XClarity控制器韌體版本、以支援雙埠Mellanox ConnectX-6介面卡。如需訂購詳細資料、請聯絡NetApp。
8.	Mellanox ConnectX-6 HCA（適用於檔案節點）。	• MCX653106A-HDAT主機通道配接卡（HDRB 200GB、雙埠QSFP56、PCIe4.0 x16）。
8.	1M HDRInfiniBand纜線（適用於檔案/區塊節點直接連接）。	• MCP1650-H001E30（1公尺Mellanox被動銅線、IB HDR、最高200Gbps、QSFP56、30AWE）。 如果需要、可調整長度以考慮檔案與區塊節點之間的距離。

數	硬體元件	需求
8.	HDRInfiniBand纜線（適用於檔案節點/儲存交換器連線）	需要長度適當的InfiniBand HDRdr纜線（QSFP56收發器）、才能將檔案節點連接至儲存葉交換器。可能的選項包括： • MCP1650-H002E26（2公尺Mellanox被動銅線、IB HDRs、最高200GB/s、QSFP56、30AWE）。 • MSFS1S00-H003E（3公尺Mellanox主動式光纖纜線、IB HDRs、最高200GB/s、QSFP56）。
2.	E系列區塊節點	兩個EF600控制器設定如下： • 記憶體：256GB（每個控制器128GB）。 • 介面卡：2埠200GB/HDR（NVMe / IB）。 • 磁碟機：設定以符合所需容量。

軟體需求

為了達到可預測的效能與可靠性、NetApp解決方案上的BeeGFS版本會測試採用實作解決方案所需的特定軟體元件版本。

軟體部署需求

下表列出在以Ansible為基礎的BeeGFS部署中、自動部署的軟體需求。

軟體	版本
BeeGFS	7.2.6
電暈器同步	3.1.5-1.
起搏器	2.1.0-8
OpenSM	OpenSM-5.9.0（從mlnx_ofed 5.4.0-1.3.0） 只有直接連線才需要啟用虛擬化。

Ansible控制節點需求

NetApp上的BeeGFS解決方案是從可存取的控制節點進行部署和管理。如需詳細資訊、請參閱 "Ansible文件"。

下表所列的軟體需求、是下列NetApp BeeGFS Ansible系列產品的特定版本。

軟體	版本
Ansible	2.11透過pip安裝時：Ansible -4.7.0與Ansible -core < 2.12、>=2.11.6
Python	3.9
其他Python套件	密碼編譯-35.5.0、netaddr-0.8.0

軟體	版本
BeeGFS Ansible收藏	3.0.00.0

檔案節點需求

軟體	版本
RedHat Enterprise Linux	RedHat 8.4伺服器實體配備高可用度（2插槽）。 檔案節點需要有效的RedHat Enterprise Linux Server訂閱和Red Hat Enterprise Linux高可用度附加元件。
Linux核心	4.18.0-305.25.1.el8_4.x86_64
InfiniBand / RDMA驅動程式	收件匣
ConnectX-6 HCA韌體	韌體：20.31.1014
PXE-3.6.0403.	UEFI：14.24.0013

EF600區塊節點需求

軟體	版本
作業系統SANtricity	11.70.2
NVSRAM	N6000-872834 - D06.dlp
磁碟機韌體	最新版本適用於使用中的磁碟機機型。

其他需求

下表所列設備用於驗證、但可視需要使用適當的替代方案。一般而言、NetApp建議執行最新的軟體版本、以避免非預期的問題。

硬體元件	安裝軟體
• 2個Mellanox MQM8700 200GB InfiniBand交換器	• 韌體3.9.2110
• 1個可控制節點（虛擬化）：* • 處理器：Intel（R）Xeon（R）Gold 6146 CPU @ 3.20GHz • 記憶體：8GB • 本機儲存設備：24GB	• CentOS Linux 8.4.2105 • 核心4.18.0-305.3.1.el8.x86_64 安裝的Ansible和Python版本與上表中的版本相符。

硬體元件	安裝軟體
• 10倍BeeGFS用戶端（CPU節點）：* • 處理器：1個AMD EPYC 7302 16核心CPU（3.0GHz） • 記憶體：128GB • 網路：2個Mellanox MCX653106A-HDAT（每個介面卡連接一個連接埠）。	• Ubuntu 20.04 • 核心：5.4.0-100-generic • InfiniBand驅動程式：Mellanox OFED 5.4.1到1.0.3.0
• 1個BeeGFS用戶端（GPU節點）：* • 處理器：2個採用2.25GHz的AMD EPYC 7742 64核心CPU • 記憶體：1TB • 網路：2個Mellanox MCX653106A-HDAT（每個介面卡連接一個連接埠）。 此系統以NVIDIA HGX A100平台為基礎、內含四個A100 GPU。	• Ubuntu 20.04 • 核心：5.4.0-100-generic • InfiniBand驅動程式：Mellanox OFED 5.4.1到1.0.3.0

版權資訊

Copyright © 2024 NetApp, Inc. 版權所有。台灣印製。非經版權所有人事先書面同意，不得將本受版權保護文件的任何部分以任何形式或任何方法（圖形、電子或機械）重製，包括影印、錄影、錄音或儲存至電子檢索系統中。

由 NetApp 版權資料衍伸之軟體必須遵守下列授權和免責聲明：

此軟體以 NETAPP「原樣」提供，不含任何明示或暗示的擔保，包括但不限於有關適售性或特定目的適用性之擔保，特此聲明。於任何情況下，就任何已造成或基於任何理論上責任之直接性、間接性、附隨性、特殊性、懲罰性或衍生性損害（包括但不限於替代商品或服務之採購；使用、資料或利潤上的損失；或企業營運中斷），無論是在使用此軟體時以任何方式所產生的契約、嚴格責任或侵權行為（包括疏忽或其他）等方面，NetApp 概不負責，即使已被告知有前述損害存在之可能性亦然。

NetApp 保留隨時變更本文所述之任何產品的權利，恕不另行通知。NetApp 不承擔因使用本文所述之產品而產生的責任或義務，除非明確經過 NetApp 書面同意。使用或購買此產品並不會在依據任何專利權、商標權或任何其他 NetApp 智慧財產權的情況下轉讓授權。

本手冊所述之產品受到一項（含）以上的美國專利、國外專利或申請中專利所保障。

有限權利說明：政府機關的使用、複製或公開揭露須受 DFARS 252.227-7013（2014 年 2 月）和 FAR 52.227-19（2007 年 12 月）中的「技術資料權利 - 非商業項目」條款 (b)(3) 小段所述之限制。

此處所含屬於商業產品和 / 或商業服務（如 FAR 2.101 所定義）的資料均為 NetApp, Inc. 所有。根據本協議提供的所有 NetApp 技術資料和電腦軟體皆屬於商業性質，並且完全由私人出資開發。 美國政府對於該資料具有非專屬、非轉讓、非轉授權、全球性、有限且不可撤銷的使用權限，僅限於美國政府為傳輸此資料所訂合約所允許之範圍，並基於履行該合約之目的方可使用。除非本文另有規定，否則未經 NetApp Inc. 事前書面許可，不得逕行使用、揭露、重製、修改、履行或展示該資料。美國政府授予國防部之許可權利，僅適用於 DFARS 條款 252.227-7015(b)（2014 年 2 月）所述權利。

商標資訊

NETAPP、NETAPP 標誌及 http://www.netapp.com/TM 所列之標章均為 NetApp, Inc. 的商標。文中所涉及的所有其他公司或產品名稱，均為其各自所有者的商標，不得侵犯。